



자연어
AI 모델
이해



다양한 AI
서비스 활용



하네스
엔지니어링



AI 활용
유의점

생성형 AI 개요

2026년 09월

- 사회 기반 시설, AI
- 자연어 처리와 ChatGPT
- 토큰과 임베딩
- 요약

사회 기반 시설, AI

AI Talk with Andrew Ng

Keynote, Fireside Chat & Networking

KBS 별관 공개홀 | 온·오프라인 동시 진행

2023.07.21.8PM



과학기술정보통신부



정보통신산업진흥원



감성 분석 테스트



아래의 내용을 0~5로 평가해 줘 (0:매우 부정, 5:매우 긍정) :
이 음식은 매우 맛있어



KSW

"이 음식은 매우 맛있어."라는 문장은 매우 긍정적인 표현이므로 5점으로 평가됩니다. 이 문장은 음식의 맛에 대해 높게 평가하고 있습니다.

m.blog.naver.com m.blog.naver.com Oops0.tistory.com



... 아래의 내용을 0~5로 평가해 줘 (0:매우 부정, 5:매우 긍정) :
이 음식은 매우 맛있어. 그런데 너무 비싸.



KSW

"이 음식은 매우 맛있어. 그런데 너무 비싸."라는 문장은 긍정적인 표현과 부정적인 표현이 섞여 있으므로 3점으로 평가됩니다. 이 문장은 음식의 맛에 대해 매우 긍정적으로 평가하고 있지만, 가격에 대해서는 부정적인 평가를 하고 있습니다. 따라서 두 가지 요소를 고려했을 때 중립에 가까운 점수를 주는 것이 적절합니다

brunch.co.kr hkn24.com youtube.com

아래의 내용을 0~5로 평가해 줘 (0:매우 부정, 5:매우 긍정) :
이 음식은 매우 맛있어. 그런데 약간 비싸.



KSW

"이 음식은 매우 맛있어. 그런데 약간 비싸."라는 문장은 전반적으로 긍정적인 표현이며, 가격에 대한 부정적인 표현이 약간 포함되어 있으므로 4점으로 평가됩니다. 이 문장은 음식의 맛에 대해 매우 긍정적으로 평가하고 있지만, 가격에 대해서는 약간 부정적인 평가를 하고 있습니다. 그러나 '약간'이라는 단어 때문에 가격에 대한 부정적인 평가는 상대적으로 약하므로, 전체 점수는 여전히 높게 유지됩니다.

brunch.co.kr hkn24.com youtube.com

... 아래의 내용을 0~5로 평가해 줘 (0:매우 부정, 5:매우 긍정) :
이 음식은 매우 맛있어. 그리고 가격도 나쁘지 않아.




KSW

"이 음식은 매우 맛있어. 그리고 가격도 나쁘지 않아."라는 문장은 음식의 맛과 가격에 대해 모두 긍정적으로 평가하고 있으므로 5점으로 평가됩니다. 이 문장은 음식의 품질과 가격에 대해 높게 평가하고 있습니다.

m.blog.naver.com blog.naver.com mangoplate.com


머신러닝 훈련은 필요한가?



AI 적용의 Long Tail



Barriers to widespread adoption #2: Customization (long tail) problem




All potential AI projects, sorted in decreasing order of value

자연어 처리와 ChatGPT

자연어 처리 (NLP – Natural Language Processing)



- 자연어(Natural Language) : 일상 생활에서 사용하는 언어
- 자연어 처리 : 자연어의 의미를 분석하여 컴퓨터가 처리할 수 있도록 하는 일
- 대표적인 NLP 연구 분야
 - ✓ 음성 인식, 문서 요약, 번역, 감성 분석
 - ✓ 텍스트 분류 : 스팸 분류, 뉴스 카테고리 분류
 - ✓ 질의 응답, 챗봇
- $NLP = NLU + NLG$




AI 학습법과 효과



지도학습 : 기존지식 전달


비지도학습 : 특성 패턴 찾기

강화학습 : 탐색 및 시행 착오




이미지 출처: <https://datasciencedojo.com/blog/machine-learning-101/>

챗GPT를 위한 훈련 (Training)



GPT, InstructGPT, ChatGPT



Pre-Training vs Post Training




기초 지식 사전 학습
(Pre-Training)



Raw intelligence



전문 지능 모방 사후 학습
(Post Training)




Usable Intelligence

Post Training 방법 : 지도학습(SFT)과 강화학습(RL)



Evolution of post-training: Fine-tuning & RL




Post Training 방법 : 지도학습(SFT)과 강화학습(RL)




Fine-tuning: How do I cook pasta?

Watch you grandma cook, step by step. Your goal is to mimic grandma!



RL: How do I cook pasta?

Your goal is to get to the right final dish. Do whatever wacky thing in between.




Major upsides of Fine-tuning & RL

Fine-tuning



It **just works** to mimic your data!

Reinforcement Learning



Can **develop** superhuman capabilities!

잘 따라 하기
(내용 모방)

능력 갖추기
(형식/절차 모방)

출처 : deeplearning.ai

주목받는 강화학습(Reinforcement Learning)



"사후 훈련에 ~~SFT 없이~~ RL만 사용하는 것이 효과적"

28 Jan 2025

SFT Memorizes, RL Generalizes:

SFT → 하나를 가르치면 하나를 안다.
RL → 하나를 가르치면 열을 안다.

사전 훈련된 언어 모델을 수
모델이 스스로 습득하는 강

홍콩대학교와 UC 버클리 연구진은 최근 인공지능의 학습 방법론을 비교 분석하는 연구를 발표했다고 보도

논문 제목은 'SFT는 기억하고, RL은 일
후 훈련에 대한 비교 연구'다.

특히 이 연구는 대형언어모델(LLM)과
정에서 수작업 라벨링된 학습 데이터를
은 수작업 예제로 학습하면 새로운 데이

지금까지 SFT 방식은 사후 학습의 표준
문-답변(QA) 형식의 수작업 예제로 추
해 더 정교한 응답을 학습하게 된다.


그러나 SFT는 데이터 수집에 많은 시간
이에 따라 최근에는 순수한 RL 방식이
학습하도록 하는 것이 핵심이다. 대표적
복잡한 추론 능력을 향상했다고 밝힌 바

또 LLM의 문제 중 하나인 '과적합'은 모
성능이 떨어진다는 점이다. RL은 이를


Fine-tuning and RL over the years

Papers published

— RL — Fine-tuning





출처 : <https://www.aitimes.com/news/articleView.html?idxno=167968>




이 SFT는 모델 출력 형식을 안정화하는 데
나타났다. 실제로 초기 SFT 단계를 거치지

언어 생성 모델




언어 생성 모델 : 확률적 단어(?) 선택



AI, 확률적 다음 토큰 예측




Predict the next token



이미지 출처 <https://wandb.ai/darek/llmapps/reports/A-Gentle-Introduction-to-LLM-APIs--Vmlldzo0NjM0MTMz>

AI 확률적 시스템 : 상식적 확률 vs 창의적 확률



LLM 의 계산은 대충? ➔ 확률적 계산




$(274 \times 301) / 9 = ?$




9109

Correct answer: **9163.78**



토큰과 임베딩

토큰 : NLP 처리의 기본 단위



출처 : <https://vinaykuma201.medium.com/language-models-building-blocks-db81dea90174>

실습 : ChatGPT 토큰 (Link : <https://platform.openai.com/tokenizer>)



GPT-4

Model	Prompt	Completion	Model	Usage
8K context	\$		GPT-4o & GPT-4o mini	tokens
32K context	\$		GPT-3.5 & GPT-4	
			GPT-3 (Legacy)	
GPT-3 Codex				
I go to school.	나는 학교에 간다.	나는 학교에 간다.		
	Clear Show example	Clear Show example		
Tokens	Tokens	Tokens		
5	11	6		
Character	Characters	Characters		
15	10	10		
I go to school.	나는 학교에 간다.	나는 학교에 간다.		
	TEXT TOKEN IDS	Text Token IDs		
[40, 467, 284, 1524, 13]		238, 220, 166, 108, 226, 46695, 97, 13]		

수) ~
5400 (token)

13, 238, 168, 245,

(영어 단어 수) = 0.75*(토큰 수), (한글 글자수) = 0.33 *(토큰 수)
 생성 콘텐츠 길이 제한, 가격 차이

실습 : ChatGPT 토큰 (Link : <https://platform.openai.com/tokenizer>)



GPT-3.5 & GPT-4		GPT-3 (Legacy)	
ha		hap	
<button>Clear</button> <button>Show example</button>		<button>Clear</button> <button>Show example</button>	
Tokens	Characters	Tokens	Characters
1	2	1	3
ha		hap	
Text Token IDs		Text Token IDs	

GPT-3.5 & GPT-4		GPT-3 (Legacy)	
happ		happy	
<button>Clear</button> <button>Show example</button>		<button>Clear</button> <button>Show example</button>	
Tokens	Characters	Tokens	Characters
2	4	1	5
happ		happy	
Text Token IDs		Text Token IDs	

GPT-3.5 & GPT-4		GPT-3 (Legacy)	
happily		happily	
<button>Clear</button> <button>Show example</button>		<button>Clear</button> <button>Show example</button>	
Tokens	Characters	Tokens	Characters
3	7	3	7
happily		happily	
Text Token IDs		Text Token IDs	

AI 인식의 구조적 차이



```
prompt == How many r's in the word strawberry?  
That's an easy one! There are 2 R's in the word "strawberry".None
```

```
prompt == How many r's in the word s t r a w b e r r y?  
There are 3 R's in the word "strawberry".None
```

3.11 과 3.9 중 어느 숫자가 커?

3.11이 3.9보다 큼니다. 소수점 첫 번째 자리까지 같지만, 두 번째 자리에서 1이 9보다 크므로 3.11이 더 큰 숫자입니다.

🔊 📄 📌 🔍 🔄 📶

How many r's in the word strawberry?

How many r's in the word s t r a w b e r r y?

GPT-4o & GPT-4o mini

GPT-3.5 & GPT-4

GPT-3 (Legacy)

3.11 과 3.9 중 어느 숫자가 커?

Clear

Show example

Tokens



14

Characters

22

3.11 과 3.9 중 어느 숫자가 커?

AI 인식의 구조적 차이



- Tokenizer 의 영향 : Unknown, 숫자, 날짜 , 오타

실습 링크 : <https://colab.research.google.com/drive/1q1y5g5QHmb2O6FYYjc3OEekMSyHSQo7f?usp=sharing>

토큰 가격 (Token Price)



GPT-5.5 코딩과 전문 작업을 지원하는 새로운 차원의 인텔리전스 가격 입력: US\$5.00/토큰 100만 개 캐시된 US\$0.5 출력: US\$30	GPT-5.4 코딩과 전문 작업에 최적화된 합리적 모델 가격 입력: US\$2.50/토큰 100만 개	GPT-5.4 mini 지금까지 공개된 소형 모델 가운데 코딩, 컴 퓨터 사용, 서브에이전트 작업에서 가장 강 력한 성능을 제공하는 모델 가격 입력: US\$0.75/토큰 100만 개
--	--	--

**[글로벌] 오픈AI, '토큰' 가격 대폭 인하 검토...엔트로픽과 가
격 전쟁 예고**

허준 편집장 | 승인 2026.06.13 09:30

←

🖨

↺

가

가

출처 : [What Is the ChatGPT Token Limit and Can You Exceed It? \(makeuseof.com\)](#)

API 토큰 가격 (Token Price) : 2026 Aug 15



Flagship models					Standard				Batch				Flex				Fast mode			
					Short context				Long context				>272K input tokens							
Our latest models																				
Prices per 1M tokens.																				
Model	Input	Cached input	Cache writes	Output	Input	Cached input	Cache writes	Output	Input	Cached input	Cache writes	Output	Input	Cached input	Cache writes	Output	Input	Cached input	Cache writes	Output
gpt-5.6-sol	\$5.00	\$0.50	\$6.25	\$30.00	\$10.00	\$1.00	\$12.50	\$45.00	\$10.00	\$1.00	\$12.50	\$45.00	\$10.00	\$1.00	\$12.50	\$45.00	\$10.00	\$1.00	\$12.50	\$45.00
gpt-5.6-terra	\$2.00	\$0.20	\$2.50	\$12.00	\$4.00	\$0.40	\$5.00	\$18.00	\$4.00	\$0.40	\$5.00	\$18.00	\$4.00	\$0.40	\$5.00	\$18.00	\$4.00	\$0.40	\$5.00	\$18.00
gpt-5.6-luna	\$0.20	\$0.02	\$0.25	\$1.20	\$0.40	\$0.04	\$0.50	\$1.80	\$0.40	\$0.04	\$0.50	\$1.80	\$0.40	\$0.04	\$0.50	\$1.80	\$0.40	\$0.04	\$0.50	\$1.80
gpt-5.5	\$5.00	\$0.50	-	\$30.00	\$10.00	\$1.00	-	\$45.00	\$10.00	\$1.00	-	\$45.00	\$10.00	\$1.00	-	\$45.00	\$10.00	\$1.00	-	\$45.00
gpt-5.5-pro	\$30.00	-	-	\$180.00	\$60.00	-	-	\$270.00	\$60.00	-	-	\$270.00	\$60.00	-	-	\$270.00	\$60.00	-	-	\$270.00
gpt-5.4	\$2.50	\$0.25	-	\$15.00	\$5.00	\$0.50	-	\$22.50	\$5.00	\$0.50	-	\$22.50	\$5.00	\$0.50	-	\$22.50	\$5.00	\$0.50	-	\$22.50
gpt-5.4-mini	\$0.75	\$0.075	-	\$4.50	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
gpt-5.4-nano	\$0.20	\$0.02	-	\$1.25	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
gpt-5.4-pro	\$30.00	-	-	\$180.00	\$60.00	-	-	\$270.00	\$60.00	-	-	\$270.00	\$60.00	-	-	\$270.00	\$60.00	-	-	\$270.00

출처 : [Pricing | OpenAI API](#)

입출력 제한 : 토큰 제한 해제 - 책 전체 요약 가능



300쪽짜리 책도 몇초만에 요약 ... 자비 없이 치고나가는 오픈AI

이덕주 기자

입력 : 2023-11-07 17:29:32

수정 : 2023-11-07 23:17:08

오픈AI는 챗GPT를 공개한 지 약 1년이 된 6일(현지시간) '오픈AI 데브데이(DevDay)'에서 후발 주자와 격차를 더욱 벌리기 위한 전략을 여실히 드러냈다.

전 세계에서 개발자 수백 명이 집결한 가운데 가장 큰 주목을 받은 것은 '맞춤형 챗GPT'였다. 그동안 챗GPT와 같은 AI 챗봇을 개인 맞춤형으로 개발하려는 시도는 많았지만 코딩을 모르는 개인에게는 높은 장벽이었다. 오픈AI는 누구든 챗봇을 학습시켜 자신만의 GPT를 구축할 수 있다고 설명했다. 샘 올트먼 오픈AI 최고경영자(CEO)는 'GPT빌더'라는 기능을 통해 스타트업에 조언하는 GPT를 만드는 과정을 시연했다. GPT 프로필 사진을 AI를 통해 생성하고, 그의 원고를 업로드한 후 "스타트업 창업자가 채용할 때 고려할 세 가지는 무엇인가"라고 질문하자 그의 원고에서 언급된 세 가지 항목으로 AI가 답을 했다. AI를 교육시키는 데 걸린 시간은 45초에 불과했다.

기존 챗GPT도 이날 새로운 모델 'GPT-4 터보'로 업그레이드했다. GPT-4 터보는 최대 300페이지까지 입력이 가능하다. 이미지를 인식하는 비전 능력, 이미지를 그리는 달리(DALLE)-3 능력, 텍스트를 음성으로 바꾸는 TTS 기능을 기본으로 탑재하고 있다. TTS에서는 총 6개 목소리를 제공한다.

한편 이날 행사에는 사티아 나델라 마이크로소프트(MS) CEO가 직접 참석해 오픈AI와의 파트너십이 든든함을 과시했다. MS는 오픈AI 주요 투자자인데, 오픈AI의 AI 서비스를 자신들의 클라우드 인프라스트럭처를 통해 고객들에게 제공하고 있다. MS는 오픈AI의 AI로 만든 서비스를 365, 원도 등에 코파일럿이라는 이름으로 서비스하고 있다.

나델라 CEO는 "나는 인프라 비즈니스를 30년 넘게 해왔는데 오픈AI와의 파트너십으로 MS 애저도 많은 변화를 했다"면서 "두 회사의 협력은 개발자들이 새로운 것을 만드는 데 큰 도움을 줄 것"이라고 설명했다.

출처 : <https://m.mk.co.kr/news/it/10868530>

더 똑똑해진 GPT-4 터보
올해 4월까지 정보 수록하고
이미지 인식·생성 기능 탑재

AI 생태계 구축 어떻게
맞춤형 GPT 만들어 올리면
애플처럼 앱스토어서 AI 거래


구글·메타 주춤할때 질주
스타트업 진입장벽 높아져
‘사다리 걷어차기’ 평가도

ChatGPT의 숨겨진 무기 – 임베딩(Embedding)



Embeddings: ChatGPT's Secret Weapon

Embeddings, and how they help ChatGPT predict the next word




(image by author)

- 컴퓨터가 다루는(다룰 수 있는) 것은 숫자
- 인공지능은 숫자를 예측한다.

출처 : [Embeddings: ChatGPT's Secret Weapon | by Emma Boudreau | Mar, 2023 | Towards Data Science](#)

과학적 접근의 기초 → 수치화 (벡터화)




셀 수 있는 모든 것을 세고, 잴 수 있는 모든 것을 재어라.

그리고 잴 수 없는 것은 잴 수 있게 만들어라

– 갈릴레오

<https://m.blog.naver.com/PostView.nhn?blogId=cjcityblog&logNo=221085979515&proxyReferer=https:%2F%2Fwww.google.com%2F>

텍스트의 수치화 : 벡터화 – 임의의 수치에 대응



단어	코드
사과	1
치킨	2
바나나	3
양배추	4

출처 : <https://subscription.packtpub.com/book/data/9781786465825/3/ch03lvl1sec32/encoding-and-embedding>

- 언어의 의미를 담지 못한 수치화

텍스트의 수치화 : 벡터화 – 임의의 독립적인 수치에 대응



Rome Paris word V

Rome = [1, 0, 0, 0, 0, 0, ..., 0]

Paris = [0, 1, 0, 0, 0, 0, ..., 0]

Italy = [0, 0, 1, 0, 0, 0, ..., 0]

France = [0, 0, 0, 1, 0, 0, ..., 0]

출처 : <https://medium.com/intelligentmachines/word-embedding-and-one-hot-encoding-ad17b4bbe111>

- 단어 표현에 큰 벡터가 필요 (One-Hot encoding)
- 언어의 의미를 담지 못한 수치화

텍스트의 수치화 : 벡터화 - 지정된 특성을 담은 수치에 대응



	Man (5391)	Woman (9853)	King (4914)	Queen (7157)	Apple (456)	Orange (6257)
Gender	-1	1	-0.95	0.97	0.00	0.01
Royal	0.01	0.02	<u>0.93</u>	<u>0.95</u>	-0.01	0.00
Age	0.03	0.02	0.7	0.69	0.03	-0.02
Food	0.04	0.01	0.02	0.01	0.95	0.97

출처 : <https://medium.com/intelligentmachines/word-embedding-and-one-hot-encoding-ad17b4bbe111>

- 단어의 특성을 결정하기 어려움
- 선택한 특성 수에 따라 벡터의 차원이 결정됨

텍스트의 수치화 : 훈련에 의한 임베딩 - 딥러닝 방식



빈도 기반 분석의 문제점

- 단어 표현에 큰 벡터가 필요 (One-Hot encoding)
- 언어의 의미를 담지 못한 수치화


언어(단어)의 의미를 수치에 담을 수 있을까?

- 문장은 의미를 갖는다.
- 같은 문장 내의 단어는 하나의 의미를 전달한다.
- 문장 내의 단어를 가까운 위치에 존재하게 만들자.


→ Word2Vec




임베딩(Embedding) 예제 Demo : Word2Vec



One-hot word vectors:
- Sparse
- High-dimensional
- Hardcoded



Word embeddings:
- Dense
- Lower-dimensional
- Learned from data



- 언어의 벡터화

- ✓ Count 기반, Tf-Idf → 통계적 방식
- ✓ 훈련에 의한 생성 → 딥러닝 (특성 추출 : Feature Extraction)

Word2Vec → 단어의 개념 수치화



```
model.most_similar(positive=['king','woman'], negative=['man'],topn=10)
Out[12]:
[('queen', 0.7118192911148071),
 ('monarch', 0.6189674139022827),
 ('princess', 0.5902431607246399),
 ('crown_prince', 0.5499460697174072),
 ('prince', 0.5377321243286133),
 ('kings', 0.5236844420433044),
 ('Queen_Consort', 0.5235945582389832),
 ('queens', 0.5181134343147278),
 ('sultan', 0.5098593235015869),
 ('monarchy', 0.5087411999702454)]
```

훈련된 문장에서 거리를 배운다
→ 영역 별 거리도 만든다

임베딩(Embedding) 예 : Word2Vec



King - Man + Woman

$$(2, 5) - (1, 3) + (1, 4) = (2, 6)$$



King (2, 5)

Man (1, 3)

Woman (1, 4)

(2, 6)

Queen (2, 6.2)



텍스트의 수치화 : 벡터화



중심 단어
주변 단어

The fat cat sat on the mat

The fat cat sat on the mat

The fat cat sat on the mat

The fat cat sat on the mat



The fat cat sat on the mat

The fat cat sat on the mat

The fat cat sat on the mat

중심 단어	주변 단어
[1, 0, 0, 0, 0, 0, 0]	[0, 1, 0, 0, 0, 0, 0], [0, 0, 1, 0, 0, 0, 0]
[0, 1, 0, 0, 0, 0, 0]	[1, 0, 0, 0, 0, 0, 0], [0, 0, 1, 0, 0, 0, 0], [0, 0, 0, 1, 0, 0, 0]
[0, 0, 1, 0, 0, 0, 0]	[1, 0, 0, 0, 0, 0, 0], [0, 1, 0, 0, 0, 0, 0], [0, 0, 0, 1, 0, 0, 0], [0, 0, 0, 0, 1, 0, 0]
[0, 0, 0, 1, 0, 0, 0]	[0, 1, 0, 0, 0, 0, 0], [0, 0, 1, 0, 0, 0, 0], [0, 0, 0, 0, 1, 0, 0], [0, 0, 0, 0, 0, 1, 0]
[0, 0, 0, 0, 1, 0, 0]	[0, 0, 1, 0, 0, 0, 0], [0, 0, 0, 1, 0, 0, 0], [0, 0, 0, 0, 0, 1, 0], [0, 0, 0, 0, 0, 0, 1]
[0, 0, 0, 0, 0, 1, 0]	[0, 0, 0, 1, 0, 0, 0], [0, 0, 0, 0, 1, 0, 0], [0, 0, 0, 0, 0, 0, 1]
[0, 0, 0, 0, 0, 0, 1]	[0, 0, 0, 0, 1, 0, 0], [0, 0, 0, 0, 0, 1, 0]

(그림3) 출처 : <https://wikidocs.net/22660>



Word2Vec 임베딩 테스트



```
test_words = ["espresso"]
out_words = model.most_similar(positive=test_words)
print( test_words[0], " most similar ===== ")
print_list(out_words)
```

```
espresso most similar =====
0 == ('cappuccino', 0.6888187527656555)
1 == ('mocha', 0.6686209440231323)
2 == ('coffee', 0.6616825461387634)
3 == ('latte', 0.6536751985549927)
4 == ('espressos', 0.6438628435134888)
5 == ('macchiato', 0.6428249478340149)
6 == ('brewed_coffee', 0.6234086751937866)
7 == ('iced_coffee', 0.6213865280151367)
8 == ('expresso', 0.6108267307281494)
9 == ('coffees', 0.6038862466812134)
```

```
test_words = ["samsung"]
out_words = model.most_similar(positive=test_words)
print( test_words[0], " most similar ===== ")
print_list(out_words)
```

```
samsung most similar =====
0 == ('htc', 0.7326198816299438)
1 == ('nokia', 0.7076619267463684)
2 == ('sony', 0.6818498373031616)
3 == ('motorola', 0.6689046025276184)
4 == ('ipad', 0.6625324487686157)
5 == ('iphone', 0.6582239866256714)
6 == ('macbook', 0.6297854781150818)
7 == ('verizon', 0.6176369786262512)
8 == ('ipod_touch', 0.6170758008956909)
9 == ('ps3', 0.607496440410614)
```

```
# Public Opinion
country = 'Japan'

pos_feeling = model.similarity(country, 'positive')
neg_feeling = model.similarity(country, 'negative')

print( country, " pos/neg == ", pos_feeling/neg_feeling)
```

```
Japan pos/neg == 1.1084418
```

```
# Public Opinion
country = 'Korea'

pos_feeling = model.similarity(country, 'positive')
neg_feeling = model.similarity(country, 'negative')

print( country, " pos/neg == ", pos_feeling/neg_feeling)
```

```
Korea pos/neg == 0.90629506
```

```
# Public Opinion
country = 'USA'

pos_feeling = model.similarity(country, 'positive')
neg_feeling = model.similarity(country, 'negative')

print( country, " pos/neg == ", pos_feeling/neg_feeling)
```

```
USA pos/neg == 34.609974
```

고전적 언어 모델 vs 딥러닝 언어 모델



승우

You

다음 세 문장, 각각의 유사도를 0.00 ~ 1.00 사이의 값으로 표시해 줘.

1. It is good.
2. It is not good.
3. It's great.

```
python Copy code

from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.metrics.pairwise import cosine_similarity

# 주어진 문장
sentences = [
    "It is good.",
    "It is not good.",
    "It's great."
]

# TF-IDF 벡터화
vectorizer = TfidfVectorizer()
tfidf_matrix = vectorizer.fit_transform(sentences)

# 코사인 유사도 계산
cosine_similarities = cosine_similarity(tfidf_matrix, tfidf_matrix)

# 결과 출력
for i in range(len(sentences)):
    for j in range(i+1, len(sentences)):
        print(f"유사도 ({i+1}, {j+1}): {cosine_similarities[i][j]}")
```

결과:

유사도 (1, 2): 0.4307690062525092

유사도 (1, 3): 0.0

유사도 (2, 3): 0.0

승우

You

User

다음 세 문장, 각각의 유사도를 벡터 임베딩 방법을 사용해서 0.00 ~ 1.00 사이의 값으로 표시해 줘.

1. It is good.
2. It is not good.
3. It's great.

```
python Copy code

import tensorflow_hub as hub
import numpy as np
from sklearn.metrics.pairwise import cosine_similarity

# Universal Sentence Encoder 모델 로드
embed = hub.load("https://tfhub.dev/google/universal-sentence-encoder/4")

# 주어진 문장
sentences = [
    "It is good.",
    "It is not good.",
    "It's great."
]

# 문장을 벡터로 임베딩
sentence_embeddings = embed(sentences)

# 코사인 유사도 계산
cosine_similarities = cosine_similarity(sentence_embeddings)

# 결과 출력
for i in range(len(sentences)):
    for j in range(i+1, len(sentences)):
        print(f"유사도 ({i+1}, {j+1}): {cosine_similarities[i][j]}")
```




결과:

유사도 (1, 2): 0.4776627128124237

유사도 (1, 3): 0.5661327838897705





유사도 (2, 3): 0.2884486310482025

임베딩 : 수치화 (벡터화)



벡터 공간에서는
의미론적 유사도 비교가 가능하다.

임베딩 : (비정형 데이터의) 의미 비교 가능



Traditional Search

```
SELECT question
FROM JeopardyQuestions
WHERE (question LIKE '%dog%' OR
question LIKE '%cat%' OR
question LIKE '%wolf%' OR
(... and so on))
```





Semantic Search

```
{
  Get {
    JeopardyQuestions {
      nearText: { concepts: ["animals"] }
    } { question }
  }
}
```

VS

출처 : <https://weaviate.io/blog/what-is-a-vector-database>

임베딩 : 유사도 비교 가능 (Q: 무엇의 유사도?, 스타일? 콘텐츠?)



출처 : <https://levelup.gitconnected.com/beyond-traditional-databases-a-look-at-vector-databases-for-machine-learning-643910fe5393>

언어 잠재 공간의 활용 - 로그 군집화



	A	I	P
20817	Main	Processing Transaction Number: 30	169
20818	Main	Processing Transaction Number: 31	169
20819	Main	Processing Transaction Number: 32	169
20820	Main	Processing Transaction Number: 33	169
20821	Main	Processing Transaction Number: 34	169
20822	Main	Processing Transaction Number: 35	169
20823	Main	Processing Transaction Number: 36	169
20824	Main	Processing Transaction Number: 0	169
20825	Main	Processing Transaction Number: 1	169
20826	Main	Processing Transaction Number: 2	169
20827	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20828	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20829	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20830	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20831	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20832	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20833	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20834	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20835	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20836	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20837	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20838	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20839	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20840	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20841	SAP_일매출자료_3_매출정산확정처리(ZSDP1003)	SAP_일매출자료_매출정산확정처리(ZSDP1003) 종료	171

새로운 로그 발생 시간		기존과 다른 정도	
126	파일 중복파일 제거	파일 확인 삭제	21 2.603045 -2
127	파일 중복파일 제거	파일 확인 삭제	21 2.603045 -2
128	WEB_EDifact_페이지 다운로드_4_CU	Find Element_검색 결과창 확인: Activity timeout exceeded	5 2.502308 -2
129	WEB_EDifact_페이지 다운로드_4_CU	Find Element_검색 결과창 확인: Activity timeout exceeded	5 2.502308 -2
130	WEB_EDifact_페이지 다운로드_4_CU	Find Element_검색 결과창 확인: Activity timeout exceeded	5 2.502308 -2
131	WEB_EDifact_페이지 다운로드_4_CU	Find Element_검색 결과창 확인: Activity timeout exceeded	5 2.502308 -2
132	WEB_EDifact_페이지 다운로드_4_CU	Find Element_검색 결과창 확인: Activity timeout exceeded	5 2.502308 -2
133	WEB_EDifact_페이지 다운로드_4_CU	Find Element_검색 결과창 확인: Activity timeout exceeded	5 2.502308 -2
134	Process_클레임 실적조회	당해_당월 클레임 다운로드_종료	10 2.385605 -2
135	Process_클레임 실적조회	전년_당월 클레임 다운로드_종료	10 2.385605 -2
136	Main	파일 삭제 : C:\1_RPA\WGO_F02600_ToplineReport작성\20220421_Output\결과.xls	8 2.308862 -2
137	Process_클레임 실적조회	<당해년도_당월 클레임 저장중>	10 2.257835 -2
138	Process_클레임 실적조회	<전년_당월 클레임 저장중>	10 2.257835 -2
139	Process_클레임 실적조회	당해_당월 클레임 다운로드_시작	10 2.257665 -2
140	Process_클레임 실적조회	전년_당월 클레임 다운로드_시작	10 2.257665 -2
141	CloseAllApplications	폴더 삭제 : C:\1_RPA\WGO_F02600_ToplineReport작성\20220421_Output\	20 2.204268 158
142	FBCRM_클레임상세_우편번호_입력	Find Element - 주소입력후 창이 안닫김 예외(2022.03.17): One or more errors occurred.	16 2.178278 110
143	Process	Invoke SAP_일매출자료_매출이관 workflow: Text was not found	19 2.144623 102
144	CloseAllApplications	폴더 삭제 : C:\1_RPA\WGO_F02600_ToplineReport작성\20220421_Input\	20 2.123563 158

- 유사한 로그 군집 → 로그 분석 시간 단축
- 유사하지 않은 로그 탐색 → 새로 발생한 로그 통지

언어 잠재 공간의 활용 - 로그 군집화



관인생략


출원번호통지서

출원일자 2022.09.14
특기사항 심사청구(유) 공개신청(무)
출원번호 10-2022-0115899 (접수번호 1-1-2022-0964895-21)
(DAS접근코드0402)
출원인명칭 위데이터랩 주식회사(1-2018-080107-0)
대리인성명 양영필(9-1998-000652-2)
발명자성명 강승우
발명의명칭 잠재 공간 기반 로그 이벤트 모니터링 시스템 및 방법

특 허 청 장



언어 잠재 공간의 활용 - 소설 문체 구분




출처 <https://arca.live/b/alpaca/178156134?p=1>

요약

요약



- 자연어 처리(NLP) = 자연어 이해(NLU) + 자연어 생성(NLG)
- 토큰(Token) : 언어 AI 모델의 최소 처리 단위
- AI의 자연어 처리 : 확률적 토큰 예측
- 임베딩(Embeddings) : 의미를 담은 숫자
 - ✓ 숫자 표현 : 비교, 계산이 편리
- 다양한 생성형 (무료) 언어 모델 사이트
 - ✓ ChatGPT : <https://chat.openai.com/>
 - ✓ 클로드 : <https://claude.ai/new>
 - ✓ Gemini : <https://gemini.google.com/app>
 - ✓ DeepSeek : <https://chat.deepseek.com/>
 - ✓



감사합니다.